



# 企业统一数据采集管理平台 SharkStart

产品白皮书

北京先进数通信息技术股份公司



# 目录

目	录	I
1.	前言	1
2.	SHARKSTART 产品概述	2
	2.1. 什么是 SharkStart	2
	2.2. SharkStart 定位与价值	3
	2.2.1. SharkStart 产品定位	
	2.3. SharkStart 产品功能架构	4
	2.4. SharkStart 特点	5
	2.4.1. 多样化数据源的支持 2.4.2. 一次采集多次使用	5
	2.4.3. 可扩展的架构	
	2.4.5. 全程数据质量监控	
	2.4.6. 便捷的开发部署方式	
	2.5. 产品技术参数	9
3.	产品功能介绍	. 10
	3.1. 配置管理	. 10
	3.2. 源数据采集	. 13
	3.3. 数据预处理	. 14
	3.4. 数据加载	. 15
	3.5. 运行监控	15
4.	应用场景或案例	. 18
	4.1. 某国有银行新一代数据仓库建设案例	. 19
	4.2. 某地方商业银行数据平台建设案例	. 20
5.	联系我们	. 20

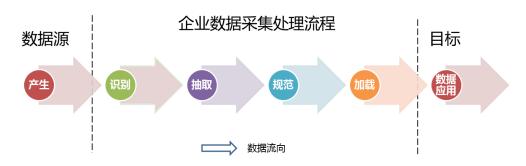


# 1. 前言

科学决策是基于对数据的分析结果,在大数据时代的背景下,企业面临着数据来源越来越广泛,数据量越来越大,数据形式越来越多样化,分析周期越来越快,如何快速、高效、准确的收集数据,直接决定大数据应用的效果。

为了解决上述问题,传统模式下需要投入大量的开发人员来应对,如果能实现数据采集的自动化,自适应数据源的增加和规格变化,屏蔽技术环境的差异,将会对大数据应用的建设和实施效果提供强力支撑。

如下图所示,数据采集过程通常包括:新增数据的识别、获取、规范化处理、 加载等过程。



在数据采集过程中,有如下关键环节需要注意:

- 1、应该保障来自于企业内外部的广泛的数据能高效而便捷地接入到企业 内部。
- 2、需保障接入源数据的准确性和完整性,并提供问题数据标识、管理、暴露和反馈的机制。
- 3、要从易用的角度出发,考虑数据的使用问题,形成统一的数据格式和信息描述,以方便后续业务应用对于数据的使用。

基于上述背景,我们认为在企业数据架构设计时,针对数据采集提供统一简便的开发、部署和管理平台是必要的。从技术上看,既可以提升数据采集质量和效率,又可以减轻开发维护工作量,将工作重心转移到数据分析与挖据上;从业务上看,既可以在保证数据一致性,又可以缩短数据获取的时间周期,提高业务的敏捷性。



# 2. SharkStart产品概述

## 2.1. 什么是SharkStart

企业统一数据采集管理平台(SharkStart)是一款用于支持企业数据采集管理的软件,是 Sharkata 产品族之一。它通过参数化、插件化、可视化的机制实现数据采集过程的自动化和统一管理,从而达到企业数据"一次采集,多次使用,易于扩展"的业务目标。

本产品提供规范、统一的企业数据采集流程管理,通过线上参数配置开发的方式,实现对各种源系统的各类型数据(结构化、半结构和非结构化)的采集、预处理(如格式标准化)、向目标加载等功能,从而为 Sharkata 或企业的其他系统提供可靠、准确的源数据。



使用 SharkStart 可以完成以下工作:

- 1、 提供一致的数据采集流程规范管控:
- 2、 提供便捷的线上开发和实时部署, 支持新增数据源的快速接入;
- 3、提供配置化、可扩展的数据源采集方式;
- 4、提供配置化、可扩展的目标加载方式;
- 5、保障数据采集的可靠性、完整性和及时性;
- 6、 通过对数据源变更的探测实现采集过程对变更的自适应;
- 7、提供数据视角的采集过程监控,数据采集可视化。



## 2.2. SharkStart定位与价值

### 2.2.1. SharkStart 产品定位

SharkStart 定位于解决企业当前数据采集面临的老问题以及应对大数据时代下数据采集的新要求。

#### 当前企业数据采集面临的老问题

- 1) 数据采集开发流程周期较长,无法快速接入新的数据源;
- 2) 手工开发的数据采集代码质量不统一, 部署及管理困难;
- 3) 数据采集过程缺乏一致性的规范约束(数据质量、采集流程);
- 4) 数据采集过程缺乏有效的监控手段,运维困难;
- 5) 源系统发生数据变更时,需要对采集程序进行调整。

#### 大数据时代企业数据采集的新要求

- 1) 数据来源越来越广泛,数据源的技术环境和数据规格差异较大;
- 2) 数据分析周期越来越短,要求能及时、高效的接入新数据源。

#### 2.2.2. SharkStart 产品价值

基于 SharkStart 进行企业数据架构搭建,可以从根本上解决企业数据采集 所面临的老问题,同时应对当前时代下对企业数据采集提出的新要求。



SharkStart 带来的价值如上图所示,可为企业的新增数据源接入、数据采集流程管理、开发效率、采集数据质量保障、应对源系统频繁的数据变更以及流程可视化监控提供有效的帮助。

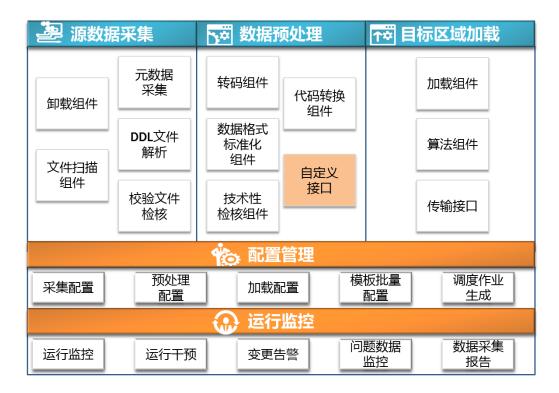
1、规范了企业数据采集流程,提升整体数据管控能力:



- 2、提高数据采集的开发效率,节省开发成本;
- 3、保障数据采集的质量,提升后续数据应用的效果;
- 4、自动化应对源系统数据的变更,提升系统的可用性;
- 5、 实现数据采集过程的可视化监控,降低运维难度。

## 2.3. SharkStart产品功能架构

SharkStart 适合企业进行数据架构优化和数据治理,可以用它构建统一数据 采集和管理平台,从而实现企业数据采集工作参数化、插件化、可视化,并进行 全流程管理,为后续的数据应用打下坚实的基础。



SharkStart 整个系统框架主要功能包括:

- 1、配置管理:提供对源数据采集、数据预处理和数据加载的配置功能,提供单个和批量的配置方式,并根据配置参数生成对应的调度作业。
- 2、源数据采集:将企业内部系统和外部的数据通过卸载、传输、链接等多种方式进行采集,并在数据缓冲区中进行存储。
- 3、数据预处理:将采集到的数据根据配置的规则进行转码、检核、格式标准化、合并等操作,使得不同源系统的数据格式统一,便于后续的使用。



- 4、数据加载:将预处理后的数据根据配置的目标进行加载。
- 5、运行监控:提供对数据采集整个过程的监控管理功能,包括采集运行过程监控,源数据变更报警监控,问题数据报警监控等。

## 2.4. SharkStart特点

#### 2.4.1. 多样化数据源的支持

SharkStart 对数据源提供了足够强大的标识、管理和扩展能力,以适应企业数据源不断增加和变更的需要。



- 1. 支持对不同技术平台上数据的采集;
- 2. 支持多种数据来源,包括数据库表、文件、消息列队等;
- 3. 支持对结构化、半结构化和非结构化数据的采集:
- 4. 支持对增量和全量数据的采集:
- 5. 支持主动和被动的数据采集方式;
- 6. 采用插件式组件设计,支持对新增类型数据源进行数据采集的扩展。

## 2.4.2. 一次采集多次使用

SharkStart 对采集到的数据规划保存至数据缓冲区,进行集中统一管理, 之后再提供给多个目标使用。这样的方式使得平台与源系统和目标保持松耦合的 关系。





Shark Start:一次采集,多次使用

#### 源数据一次采集

对一个源数据进行单次采集,避免重复的对源系统抽取数据,减轻源系统压力。

#### 采集数据多次使用

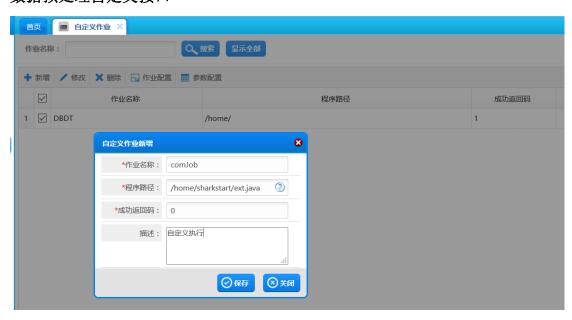
一份数据在不同数据应用中多次使用,保证不同数据应用获得的源数据是一 致的。

#### 2.4.3. 可扩展的架构

#### 数据采集和数据加载插件化设计

SharkStart 在源数据采集和目标加载过程所调用的组件,都按插件化的方式进行设计,可方便的进行扩展,实现对新的技术平台的支持。

#### 数据预处理自定义接口



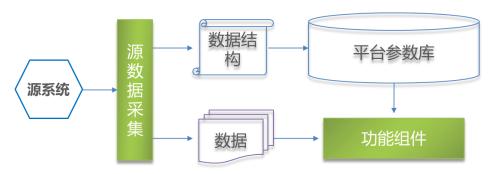


SharkStart 在数据预处理环节中提供自定义接口,方便用户根据自身处理需要,在原有预处理流程中扩展新的数据处理功能。

## 2.4.4. 源数据变更全程自适应能力

在传统的数据采集开发模式下,一旦出现源系统数据规格的调整变更,开发人员需要根据新的数据规格调整原有的采集程序,并遵循开发测试的流程后才能部署。这样对于周期较为紧急的变更和临时未通知的变更,往往需要投入大量人力和时间。

通过分析数据采集过程可以发现,各个数据的处理是相对独立的,除了在实体上不同,其最主要的区别是在数据结构上。在 SharkStart 中,各流程环节使用的功能组件都将数据结构作为输入参数。



在数据采集流程的源数据采集阶段,会首先采集数据的结构信息装载至参数 库中。在后续处理的各功能组件,在运行时将实时的读取在参数库中对应的结构 信息。通过这样的方式,实现数据采集过程对变更的自适应。

## 2.4.5. 全程数据质量监控

#### 数据采集的完整性保障

SharkStart 在数据采集过程的各处理环节都进行了严密的数据量完整性检验。在各个环节的处理过程中都对输入输出数据量进行了比较,确保处理的数据量一致。

#### 数据采集的一致性保障

在数据预处理中使用的各个功能组件都有严格的数据质量控制环节,确保数据预处理过程中不造成数据的丢失。





#### 数据质量报告机制



对于采集、预处理和装载过程中发现的数据问题,用户可以在运行监控中方便的进行查看,同时也将体现在定期生成相应的数据采集报告中。

## 2.4.6. 便捷的开发部署方式

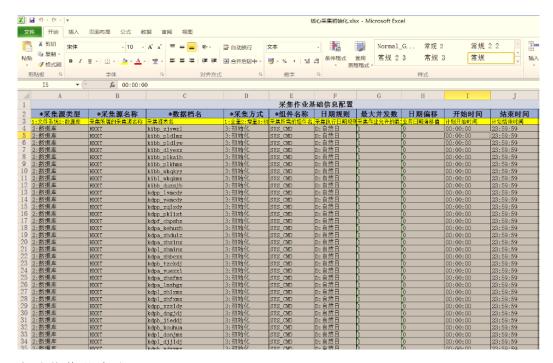
#### 可视化在线配置

SharkStart 中通过参数化的方式,实现对新增数据源的支持,通常情况下用户无需开发代码,而是通过在线配置的方式即可方便的接入新增数据源。

#### 手工批量配置

为了适应工程的需要,产品还提供了批量配置方式,用户根据 EXCEL 模板,填写数据采集项的各种参数信息,通过配置批量导入方式生成数据采集的参数配置信息。





#### 自动化作业生成

当数据采集配置完成后,系统将对它们进行验证,验证无误后用户可以进行 生效操作。生效过程中将根据配置信息自动的生成作业及调度信息。

这样的开发部署方式,极大的提高了数据采集的开发效率,满足了用户对数据的及时性要求。

## 2.5. 产品技术参数

技术参数描述				
技术参数		是否支持	备注	
支持数据库类型	Oracle	√		
	DB2	√		
	Greenplum	√		
	Teradata	√		
	Hadoop	√		
	数据库直抽	√		
支持数据采集方式	文件采集	√		
	消息	√		
半结构化数据支持		√		
非结构化数据支持		√		
产品运行环境描述				
操作系统	作系统 AIX 5.3以上/Red Hat Linux Advanced Serve		erver 3.0以上	
参数库	Oracle 9i 以上/DB2 V9.7 以上 WebLogic/Websphere/Tomcat			
WEB 服务器				
软件环境	DataStage(需要运行框架 Orchestrate)			
	Oracle 客户端			
	Perl (需包含所关联数据库 DBI)			



宏白些	Windows XP/Vista
客户端	IE 9.0 及以上

# 3. 产品功能介绍

# 3.1. 配置管理

#### 源数据采集配置管理

在 SharkStart 中将所需要采集的源系统数据,按源系统->采集源->采集项的层次方式进行组织。



通过这样的组织方式,将源数据的实体信息和采集特征进行了抽象分离,形成统一的源数据采集参数,便于后续的配置开发。

SharkStart 源系统指的是上游的业务系统,采集源是指一个源系统下的一个数据实体集,一个源系统中可以包含一个或多个采集源。每个采集源配置信息包括:数据接口类型、位置属性、采集条件等。





SharkStart 采集项是指一个源系统的数据实体,一个采集源下存在一个或多个采集项,每个采集项对应的就是需要采集的源数据,采集项配置信息包括: 采集项信息、采集条件、采集频率、采集参数等。



完成配置后,根据源系统及采集源组织生成调度中的采集任务,并在任务下生成对应的源数据采集作业。

#### 数据预处理配置管理

数据预处理配置管理提供对数据预处理过程中涉及的流程和参数进行配置。

每个数据的数据预处理流程都包括固定处理流程,其中包括数据格式标准化和技术性检核。为了满足用户对数据预处理的其他要求,产品允许通过数据预处理配置在固定流程中添加可选流程(如产品内置的转码和格式转换),用户也可以添加自定义流程。

配置完成后,将根据配置的流程生成对应的数据预处理作业和作业流,并按源系统和采集源组织生成调度中的预处理任务。

同时数据预处理配置功能提供对数据预处理流程使用的参数进行配置。数据 预处理通常根据源数据采集获取的数据结构信息作为参数对采集数据进行预处 理操作,使用数据预处理配置可对使用的数据结构信息进行变更,满足特殊的处 理要求。提供的配置包括:字段映射、数据检核。





以上配置将在数据预处理的过程中实时生效。

#### 数据加载配置管理

在 SharkStart 中将所需要向目标加载的数据,按目标区域->加载数据项的 层次方式进行组织。

SharkStart目标区域指的是一个下游业务系统的数据集,是数据的需求方。每一个目标区域有一个唯一的标识,并且后续是我们进行数据加载管理的基本单位。每个目标区域特征信息包括:数据接口类型、位置属性。

SharkStart 加载数据项是指一个目标区域的数据实体,一个目标区域下存在一个或多个加载数据项,每个加载数据项对应的就是目标中需要加载的数据,加载数据项包括:加载数据项信息、源数据、目标数据存储方式。

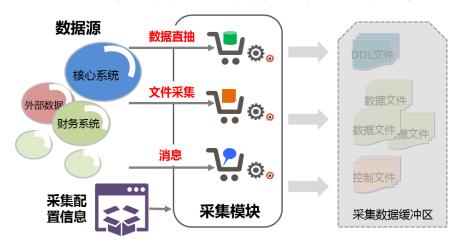




完成配置后,根据源系统、采集源和目标区域组织生成调度中的目标加载任务,并在任务下生成对应的加载作业。

## 3.2. 源数据采集

SharkStart 提供对数据源进行数据读取,并落地保存至缓冲区的功能。



#### 数据直抽

对数据库表中数据进行采集,调用卸载组件连接源系统数据库,读取数据, 形成数据文件保存在缓冲区中,同时配套生成数据结构文件(DDL 文件)和控制文件。

数据结构文件记录着数据结构信息,在采集后处理中解析更新至参数库,并 供后续功能组件使用。

控制文件记录着数据的条数,数据文件字节数大小和生成时间信息,在采集后处理中解析更新至参数库,并供后续功能组件在读取数据文件时先对文件的完整性进行校验。

#### 文件采集



调用文件扫描组件对源系统文件区进行扫描,当所需数据文件存在时,将数据文件读取保存至缓冲区。同时对数据文件配套的数据结构文件和控制文件进行校验。

当存在数据结构文件时,文件扫描组件需要对数据结构文件进行解析,获取 数据结构信息更新至参数库。

当存在控制文件时,文件扫描组件需要对控制文件解析,获取文件的条数,数据文件字节数大小和生成时间信息,与实际情况比较进行校验。

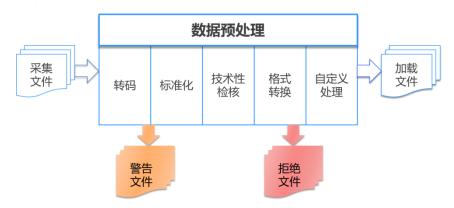
#### 消息采集

在消息缓冲区中生成消息队列,接收消息并保存。

## 3.3. 数据预处理

SharkStart 提供对采集到的数据进行预处理的功能,目标实现数据格式规范统一,方便后续应用使用。数据预处理原则保证数据的原汁原味,只进行数据格式的改变,不进行数据的业务含义进行改变。

经过预处理后的源数据按照配置的数据组织方式,以数据文件方式在缓冲区中讲行存储。



#### 基本处理流程

- 1、数据格式标准化:对数据的格式进行标准处理,如数值的补位,日期格式的标准统一。
- 2、技术性检核:对数据的结构与值进行类型和长度校验,如对字段超长,数值字段中出现字母的情况进行检查。

#### 可选处理流程

1、转码:对EBCDIC码至ASCII码的转换。



2、格式转换:根据目标的格式要求对数据进行格式转换,如对数据的字段进行筛选,字段顺序进行重新排列组织,数据内码转换,字段类型进行变更。

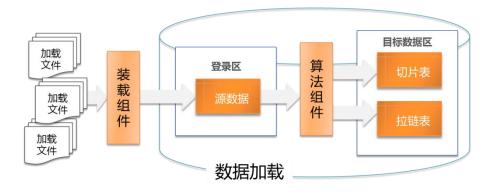
#### 自定义处理流程

调用用户自定义的外部组件进行数据处理。

## 3.4. 数据加载

SharkStart 提供将缓冲区中保存的源数据向目标加载的功能。

#### 数据库表加载



调用加载组件将数据加载至目标数据库。对于数据库表的数据加载, SharkStart 提供的不是简单的加载。这类加载首先将数据加载至目标数据库的 临时区,然后再根据配置信息,调用相应算法组件,将数据加载至最终目标数据 库表中。

产品支持的目标数据库表的数据存储组织类型包括: 当前全量表、增量切片表、拉链表。

#### 文件数据加载

拷贝或调用指定程序将数据拷贝至目标指定位置。

## 3.5. 运行监控

SharkStart 提供用户可以通过作业和数据两个视角对数据采集的过程进行监控及干预操作。

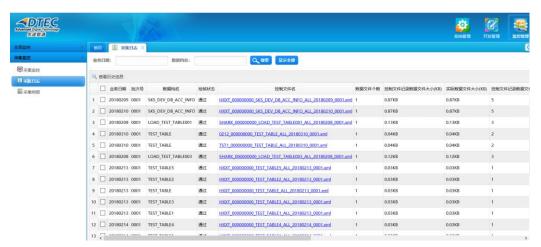


## 3.5.1. 采集监控

#### 3.5.1.1. 源数据采集监控



提供报表图形,根据源系统及其所属采集源的视角对当前采集情况进行监控。同时提供对采集数据的情况进行汇总和明细监控。



#### 3.5.1.2. 变更公告

将发生数据规格变更的源系统和对应的数据进行通告。



## 3.5.2. 总体监控



总体监控负责对从采集、检核、加载到入库过程中的所有处理步骤进行监控, 提供成功和报错提示,并能根据处理对象查看到所属源系统当前运行情况。

#### 3.5.2.1. 数据预处理监控

根据源系统及其所属采集源的视角,对预处理情况进行汇总和明细监控。

#### 3.5.2.2. 数据加载监控

根据源系统、采集源和目标区域的的视角,对加载情况进行汇总和明细监控。

#### 3.5.2.3. 数据质量监控

对数据采集各环节所处理的数据量进行监控,并对各个环节所产生的问题数据进行告警。

#### 3.5.3. 平台报告

汇总统计每日数据采集的相关运行信息、数据量信息、警告信息和问题数据 信息,形成报告。并在页面提供对报告的查看和下载操作。





# 4. 应用场景或案例

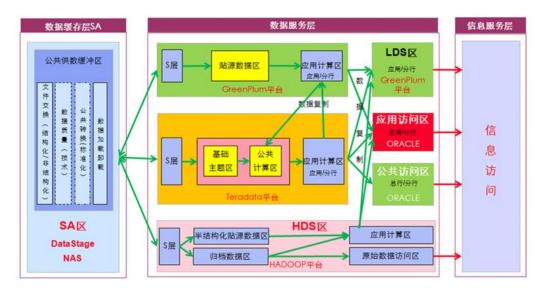
# 4.1. 采集卸数的一般配置

- ▶ 获取采集源表名
- ▶ 新建源系统和数据库
- ▶ 新建采集源
- ▶ 新建采集作业
- ▶ 调度采集





## 4.2. 某国有银行新一代数据仓库建设案例



该银行采用多技术平台建设新一代企业级数据仓库。仓库中存在多个技术平台,包括TD、GP、Hadoop、Oracle、NAS。

为了降低系统间的耦合度和实现数据的一次采集多次使用,建立统一的数据缓冲区(SA区),由它收集来自源系统的数据,经过预处理后,分别向多个技术平台进行加载。同时建立基于GP平台的贴源数据区,保存66日的切片数据和历史拉链数据,以满足仓库各个分区快速用数及恢复数据的要求。并要求在数据文件到达的情况下,以不低于2小时的指标完成数据预处理并加载至贴源区。并且在仓库建设期间,面临着上游源系统大量的变更和数据重构的情况。

该行通过本产品来实现源数据统一采集和贴源数据区的建设,实现了数据采集和贴源数据区加载的零代码开发,并能对源系统变更自动适应。系统上线运行后每日处理由70多个源系统的数据,涉及8000多个数据实体,90000多个数据文件,日增量数据约为3.5T,时效性完全满足预期。



## 4.3. 某地方商业银行数据平台建设案例



该银行进行新一代大数据平台建设,需要对企业内部 x 个源系统的数据进行 采集,这些源数据主要保存在 Oracle 和 DB2 中,通过直接抽取的方式获得数据。 同时建立贴源集市管理源数据,并向下游多个系统提供数据服务。由于数据平台 建设期间正面临该行进行新一代核心系统的升级改造,多个业务系统处于配套变 更中,因为在开发和上线阶段都面临着上游系统频繁变更的情况。

采用本产品构建了统一数据采集平台和贴源集市。本产品提供的在线配置的 开发方式,以及对变更的自适应,极大的提升了开发效率,相比传统的手工编码 开发方式,节省了60%以上的开发工作量。

系统上线后,运行稳定,维护便捷,超过了预期效果。

## 5. 联系我们



北京先进数通信息技术股份公司

http://www.adtec.com.cn

电话: 010-68700075, 010-68700009

邮件支持: <u>sharkStart@adtec.com.cn</u>

微信公众号: adt-bigdata

公司简介



北京先进数通信息技术股份公司(以下简称先进数通)是中国金融信息科技的重要参与者和领先企业。公司总部位于北京中关村科技园区,在上海、广州、成都、武汉、厦门、深圳、重庆设立了分公司,办事处及服务网点遍及全国 30 余个中心城市,形成了强大的支持服务网络。

自 2000 年成立以来,先进数通始终致力于以金融信息化为核心的软件解决方案、IT基础设施建设和 IT 运维服务。历经多年的稳健发展,业务已涵盖银行、保险、证券及企业等多个领域,为约 400 家金融企业及其他用户提供 IT 解决方案和专业服务,包括五大国有商业银行、股份制商业银行、区域银行及邮储银行、政策性银行、保险、证券、企业等。

秉持"诚信为本、艰苦奋斗、荣辱与共"的核心价值观,凭着稳健、进取的核心团队,领先的技术研发能力和自主知识产权,丰富的金融行业积淀和共创价值的合作伙伴,先进数通专注耕耘十余载,在金融前置与渠道应用、数据管理与商业智能应用、企业大数据平台、数据中心网络建设、行业云平台、企业网络及IT 运维服务等领域打造出领先的综合竞争力,不断为客户提供高业务价值的产品和服务。

- ◆ 中国软件自主可靠企业核心软件品牌、中国软件行业(金融领域)优秀 企业奖
- ◆ 最具投资价值方案商 TOP50、十佳大数据方案商、十佳银行行业方案商
- ◆ 中国方案商百强企业、银行行业方案商十强
- ◆ 十大金融科技杰出企业奖、金融科技企业创新奖、十大金融科技企业用 户信赖产品奖